

출품번호

제72회 전국과학전람회

물성 기반 3D 분자 구조 예측
딥러닝 모델 개발

2026. 8. 4.

출품학생	
지도교원	
구 분	학생부
출품부문	화학

【 목 차 】

I. 연구 동기 및 목적	1
1. 연구 동기	1
2. 연구 목표	2
II. 이론적 배경 연구	3
1. 선행 연구	3
III. 연구 내용	4
1. 데이터 모델링 및 전처리	4
2. 1차 모델 (Molecule Graph CVAE)	6
3. 2차 모델 (Molecule Graph Diffusion)	14
IV. 결론 및 향후 계획	21
1. 결론 및 기대효과	21
2. 향후 발전 방향	21
V. 참고문헌	23
VI. 부록	25

【 그림 목차 】

[그림 1] 기존 신약 개발 과정	1
[그림 2] Autoencoder의 모델 구조	6
[그림 3] CVAE의 모델 구조	7
[그림 4] MoleculeCVAE 모델 구조	11
[그림 5] MoleculeGraphDiffusion 모델 구조	15

【 표 목차 】

<표 1> 5가지 물성	5
<표 2> 노드 피쳐(Node feature)	5
<표 3> 엣지 피쳐(Edge feature)	5
<표 4> 마스크 비율에 따른 원자/결합 정확도	17

【 그래프 목차 】

<그래프 1> beta cyclical cosine annealing	9
<그래프 2> 모델 학습 Loss	12
<그래프 3> threshold에 따른 validity	12
<그래프 4> threshold에 따른 uniqueness	13
<그래프 5> 엣지 상호작용 항 추가 전후 validity 비교	17
<그래프 6> Noise Model에 따른 validity 비교	18
<그래프 7> Absorbing 방식 학습 loss	19
<그래프 8> Marginal transition 방식 학습 loss	19
<그래프 9> 결합 표현 방식에 따른 이론적 validity 상한	20


I

연구 동기 및 목적

1. 연구 동기

가. 기존 신소재, 신약 개발 과정의 비효율성

기존의 신약 개발 과정은 다음과 같이 크게 4가지 단계로 나뉜다.



[그림 1] 기존 신약 개발 과정

개발 후보물질 선정 단계(Drug Discoveries) → 전임상 (비임상) 시험 단계(Preclinical) → 임상 시험 과정(Clinical Trial) → 신약 승인 및 판매라는 모든 과정을 거친 후에야 신약으로써 사용이 가능하다 [1]. 이 과정 중 개발 후보물질 선정 단계에서 5000개에서 10000개의 후보 화합물(Compounds)를 전부 Random Screening에 의한 탐색을 진행하기 때문에 3년에서 최대 5년까지 걸릴 정도로 상당히 많은 시간을 차지한다.

기존 신소재 개발 과정 또한 신약 개발과 유사하게 후보 물질을 설계하고 합성하고 측정하는 시행착오적 과정을 반복한다. 특히 원하는 성질의 물질을 찾기 위해서는 신약 개발과 마찬가지로 수천에서 수만 개의 경우의 수를 직접 확인해야 한다.

이처럼 신약 개발과 신소재 개발 중 후보 물질 선정 과정에서 발생하는 막대한 비용과 시간은 최종적으로는 개발된 신약과 신소재 자체의 가격을 상승시키는 요인 중 하나이다.

나. 기존 양자화학 계산의 한계

어떤 분자의 물성을 예측하기 위해서는, 그 구조와 그들간의 상호작용을 계산해야 한다. 하지만, 원자나 아주 간단한 분자가 아니라면, 수많은 원자끼리의 상호작용을 모두 이론적으로 계산해내기는 매우 힘들다. 특히, 파동함수를 직접적으로 계산하고 조합하는 고전적 방식은 계산해야 할 원자 수가 조금만 늘어나도 계산량이 급격히 증가하게 되며 이를 전부 계산하는 것은 불가능하다. 이에, 현대에서는 단순히 전자들의 분포 확률을 나타내는 확률 밀도 함수를 계산하며 각 원자의 상호작용 관계를 분석하는 밀도범함수 이론(Density Functional Theory)이 도입되어 사용되고 있다 [2]. 다만, 밀도범함수 이론은 이미 존재거나, 구조가 만들어진 분자의 특성을 추정하기만 할 뿐, 원하는 분자의 구조를 생성하거나 파악하는데 사용될 수는 없다.

다. 머신러닝과 GNN을 활용한 분자 특성 예측 모델의 발달

최근 머신러닝 기술의 발전으로 이를 화학 분야에서 기존에 알려진 분자들의 화학적 특

성을 기반으로 새로운 분자의 특성을 예측하는 등의 활용이 확대되고 있다. 그 중에서도 특히 분자 구조를 그래프의 형태로 표현한 뒤 GNN(Graph Neural Network)를 활용해 분자의 특성을 추출하는 등 GNN을 활용한 연구가 활발히 진행되고 있다. 이를 통해 기존의 SMILES 식 등 문자열을 기반으로 학습하는 방법보다 원자 간 결합과 각 원자의 특성을 더욱 잘 반영할 수 있다는 장점이 있다. 하지만, 위와 마찬가지로 이들은 이미 형성된 구조의 분자 특성을 예측하는데 초점이 맞춰져 있으며, 그 역은 수행할 수 없다.

2. 연구 목표

본 연구의 목표는 원하는 분자의 물성 조건과 원자 조성을 입력으로 받아 가장 안정한 3차원 분자 구조를 생성할 수 있는 딥러닝 기반 조건부 분자 생성 모델을 설계하고 검증하는 것이다. 기존의 분자 물성 예측 시스템은 주로 분자식이나 2차원 분자 그래프 입력을 받아 HOMO, LUMO, 에너지 갭, 전체 에너지 등의 물성을 예측하는 순방향 탐색 구조를 가진다. 이러한 모델은 이미 존재하는 분자를 빠르게 예측할 수 있다는 장점이 있지만 실제로 어떠한 물성을 만족하는 새로운 분자구조를 직접 생성하는 것에는 한계가 있다.

따라서 본 연구에서는 기존 물성 예측 방식에서 더 나아가 목표 물성으로부터 분자 구조를 역으로 생성하는 조건부 생성 모델을 개발하고자 한다. 이를 위해 분자를 원자가 결합되어 있는 그래프 형태로 바꾸어 표현한 후 물성 정보와 원소 조성 정보 데이터셋을 이용해 해당 조건을 만족하는 분자 결합 구조를 생성하는 모델을 설계하려 한다.

구체적으로는 QMugs 데이터셋에 포함된 DFT 수준의 양자화학 계산 결과를 활용하여 HOMO 에너지, LUMO 에너지 쌍극자 모멘트 등의 물성 정보를 학습 데이터로 사용한다. 모델은 이러한 물성조건과 원자 조성 조건을 입력받아 분자 내 원자들의 결합 여부를 예측할 수 있도록 학습해 최적에 경우를 찾아내는 것이다.

1. 선행 연구

가. Automatic Chemical Design Using a Data-Driven Continuous Representation of Molecules

이 연구에서는 머신러닝을 활용해 기존의 불연속적인 상태로 표현되던 분자를 잠재 차원 (Latent Space)에 표현하고, 이를 바탕으로 목적에 맞는 새로운 분자를 설계하는 개념을 제시했다. 이 연구에서는 SMILES와 같은 문자열을 기반으로 VAE(Variational Autoencoder) 모델을 구성하여 분자 구조를 저차원 벡터로 압축하고 복원하는 방식을 제안했다. 이는 무작위 탐색에 기반한 기존의 신소재, 신약 개발의 방식에서 벗어나 데이터 기반의 탐색을 바탕으로 목표하는 물성을 띄는 화합물을 효율적으로 생성할 수 있는 가능성을 보여주었다. 하지만 선형 문자열인 SMILES를 기반으로 한 학습은 원자 간의 결합을 충분히 반영하지 못한다는 단점이 있다. 또한, 연속적인 상태로 바꾸는 과정에서 화학적 유효성이 크게 떨어진다는 단점도 존재한다.

나. Junction Tree Variational Autoencoder for Molecular Graph Generation

이 연구에서는 기존 문자열 기반 모델과 원자 단위 생성 방식이 가지는 화학적 유효성의 저하 문제를 해결하기 위해 분자를 화학적으로 유효한 부분 구조의 조합으로 생성하는 JT-VAE(Junction Tree-Variational Autoencoder) 모델을 제안했다. 이 모델은 분자를 트리 형태의 뼈대(Scaffold)로 먼저 구성한 뒤, 각 부분 구조를 조립하는 두 단계를 거친다. 이를 통해 생성 과정 내내 화학적 유효성을 유지하며 제약 조건 기반 최적화를 통해 원하는 물성의 분자를 합성할 수 있음을 보였다.

다. 안전한 화학제품 설계를 위한 딥러닝 기반 화학물질 기능 및 용도 예측모델 개발

이 연구에서는 기존에 알려진 화학물질 데이터를 그래프 형태로 표현하고, GNN(Graph Neural Network) 기술 중 하나인 GCN(Graph Convolutional Network)을 활용하여 물질의 기능과 용도를 예측하는 순방향 탐색 모델을 다루었다. 원자 간 결합 구조를 기반으로 물리화학적 성질을 높은 정확도로 추출할 수 있음을 보여주었으나, 거시적인 연결 여부 위주의 GCN 알고리즘은 단일, 이중 결합이나 방향족성 같은 구체적인 결합 특성을 연산에 직접 반영하지 못하고 이성질체 등 미세하게 다른 구조를 구별하는 능력에 한계가 있다.

라. QMugs: Quantum mechanical properties of drug-like molecules

이 연구에서는 약물 설계 및 분자 특성 예측을 위한 인공지능 학습에 최적화된 대규모 데이터셋인 QMugs를 구축했다. 이 데이터셋은 단순한 근사값이 아닌 밀도범함수이론(DFT)을 통한 양자화학 계산을 통해 도출된 약 200만 개의 기하학적 이성질체 구조 데이터를 포함하고 있다. 분자의 3차원 입체 구조 정보뿐만 아니라 HOMO, LUMO 에너지, HOMO-LUMO 차이, 쌍극자 모멘트 등 분자의 물리화학적 성질을 확인할 수 있는 양자화학적 물성 정보를 포함하고 있다. 이에 이 데이터셋에 포함된 물성과 분자를 구성하는 원소의 종류 등을 학습에 사용하였다.

1. 데이터 모델링 및 전처리

분자의 화학적 물성이 주어졌을 때 분자의 구조를 생성하는 것이 모델의 목표이다. 모델이 유의미한 예측을 수행하기 위해서는 모델이 입력받고 출력하는 데이터의 특성들을 적절히 선정해야 해야 한다.

우선 최종적으로 모델이 출력해야 하는 목표를 설정하였다. 본 연구에서 구현하려는 시스템의 최종 목표는 3차원 분자 구조를 생성하는 것이지만, 모델의 잠재 표현 내에서 분자 구조 내에서 원자들의 3차원적 배치까지 학습하게 된다면 모델의 크기가 과도하게 커지고 학습이 제대로 진행되지 않을 것이라고 판단해 모델이 3차원 구조가 아닌 결합 관계만을 그래프 데이터 구조로 출력하도록 설계하였다. 또한 신소재, 신물질 개발 과정에서는 물성을 만족하는 분자 구조 중에 가장 에너지가 낮은 안정한 구조를 탐색하는 것이 일반적이므로 생성된 분자 내 원자 결합 구조를 바탕으로 기존 양자 화학 이론을 활용하여 가장 안정적인 3D 분자 구조를 최종적으로 계산하도록 할 것이다.

모델의 입력되는 데이터의 경우 생성하고자 하는 분자의 물성이 될 것이다. 이때 물성의 종류에 따라 모델에게 제공되는 정보의 양과 제약조건의 범위가 변화하기 때문에 같은 구조의 모델에서도 학습 난이도가 크게 달라질 것이다. 만약 예측에 필요한 정보보다 더 적은 양의 정보만 제공한다면 학습이 제대로 이루어지지 않거나, 생성되는 분자들의 범위가 매우 넓어 생성 결과를 실제 신소재, 신물질 개발에 활용할 수 없을 것이다. 반대로 너무 많은 정보를 제공한다면 과도한 분자 물성 제약조건으로 인해 모델이 조건을 만족하는 분자를 생성하지 못할 수 있다는 문제가 있다. 이에 따라 충분한 물성 데이터가 존재하면서 충분히 다양한 종류의 분자가 존재하는 데이터셋을 탐색하였다.

학습에 사용한 데이터셋은 QMugs라는 데이터셋이다 [3]. QMugs는 약물 설계와 분자 특성 예측을 위한 인공지능 학습에 최적화된 대규모 데이터셋으로 총 200만 개의 분자 구조 데이터를 포함하고 있고, 데이터셋 내 모든 분자의 에너지가 단순한 근사한 값이 아닌 밀도 범함수 이론(DFT) 수준의 정밀한 양자 화학 계산을 통해 도출되었다. 분자의 구조 뿐만 아니라 에너지, 전하, 쌍극자 모멘트 등의 추가적인 정보도 포함하고 있어 본 연구에서 개발하고자 하는 모델 학습에 적합하다고 판단해 QMugs 데이터셋을 사용하게 되었다.

QMugs는 ChEMBL database에서 추출한 생물학적, 약리학적으로 중요한 665,000개의 분자에 대한 200만 개의 이성질체를 포함하고 있는 데이터셋이다. 데이터셋 내에는 각 분자에 대한 물성과 DFT(밀도범함수이론) 수준의 양자화학 계산 데이터가 포함되어 있다. 그 중에서 본 연구에서는 5가지 물성을 추출하여 사용하였다.

<표 1> 5가지 물성

DFT_HOMO_ENERGY	HOMO 에너지, 전자를 가장 쉽게 내어주는 정도 (전자 공여성)
DFT_LUMO_ENERGY	LUMO 에너지, 전자를 가장 쉽게 받아들이는 정도 (전자 수용성)
DFT_HOMO_LUMO_GAP	HOMO-LUMO 갭, 반응성
DFT_TOTAL_ENERGY	전체 에너지, 열역학적 안정성
DFT_DIPOLE_TOT	쌍극자 모멘트, 극성/무극성

각 물성은 단위도 다르고 값의 스케일도 다르기 때문에 모델이 모든 물성을 같은 가중치로 인식할 수 있도록 전체 데이터를 통계로 z-score 정규화를 진행하였다.

$$p_{norm} = \frac{(p-m)}{\sigma}$$

위 물성과 함께 각 분자는 원자를 의미하는 노드 피쳐, 결합을 의미하는 엣지 피쳐를 추가로 가진다.

<표 2> 노드 피쳐(Node feature)

z	원자 번호
charge	형식 전하
chirality	분자의 비대칭적 기하학적 특성

<표 3> 엣지 피쳐(Edge feature)

bond_type	결합 종류 (단일결합/이중결합/삼중결합/방향족)
bond_stereo	결합 입체 구조 (None/Cis/Trans/E/Z)
dihedral	이면각

모델의 생성 분자의 범위를 일정 범위 내로 제한하여 조금 더 유의미한 결과를 얻기 위해 물질뿐만 아니라 모델에서 고려하는 원자 종류의 범위도 제한하였다. 모델에 입력 가능한 원자의 종류는 아래와 같이 선정하였다.

C, H, O, N, S, P, F, Cl, Br, I

이와 같이 선정한 이유는 선행 연구 중, 대규모 화학 구조 데이터베이스인 PubChem에서 '유기 분자에서 가장 빈번하게 발견되는 원소들로 C, N, O, S, P 및 할로젠 원소'를 사용했고 [4], QMugs 데이터셋에서도 마찬가지로 위의 10가지 원소(C, H, O, N ...)를 사용했다 [5]. 이는 위 원소들이 유기 분자 내에서 가장 빈번하게 발견되는 것이며, 할로젠 원소들이 생물학적 활성을 조절하는데 기여하기 때문이다.

전처리를 진행한 데이터셋은 학습에 사용되기 위해 train 80%, validation 10%, test 10%의 비율로 분할하였다.


2. 1차 모델 (Molecule Graph CVAE)

가. 모델 설계

본 연구의 목표는 모델이 물성 정보를 입력받으면 이를 만족하는 분자 구조를 생성하는 것이기 때문에 데이터의 특성을 학습하고, 이를 기반으로 새로운 데이터를 생성할 수 있는 생성 모델을 사용해야 한다. 생성 모델에는 다양한 구조가 존재한다. 대표적인 3가지 구조로는 One-shot Model, Autoregressive Model, Diffusion Model이 있다. Embedding Model은 VAE(Variational Autoencoder)와 같이 고차원의 데이터를 저차원의 latent space로 압축했다가 한번에 펼치는 방식으로 생성한다. 고차원의 데이터에서 핵심적인 특성을 추출하여 잠재 공간에 표현하는 것이 핵심이다. Autoregressive Model은 데이터를 한 번에

생성하는 것이 아닌, 이전 단계의 생성 결과를 바탕으로 다음 단계를 예측하는 형태로 순차적인 예측을 수행하는 모델이다. Diffusion Model은 완전한 노이즈 상태에서 노이즈를 제거하는 denoising을 반복하며 데이터를 복원해나가는 방식으로 데이터를 생성하는 모델이다. 이 3가지 구조 중 1차 모델에서는 가장 설계가 간단한 One-shot Model 방식을 택하였고, 이 중에서도 VAE를 변형한 CVAE(Conditional Variational Autoencoder)를 사용하여 구현하였다.


Autoencoder는 비지도 학습 기반의 신경망으로 입력 데이터를 저차원의 잠재 공간(Latent Space)로 압축한 후 다시 원래 데이터로 복원하도록 모델을 학습하는 방식으로 데이터의 특징을 추출하는 구조의 신경망 모델이다. Autoencoder는 데이터 내에서 핵심 특징과 패턴을 추출하여 압축하는 인코더(Encoder)와 디코더(Decoder)로 구성된다.



[그림 2] Autoencoder의 모델 구조

모델의 학습 목표는 입력과 출력 사이의 재구성 오차(reconstruction loss)를 최소화하는 것으로, 일반적으로 MSE Loss(Mean Squared Error Loss)를 손실함수로 사용한다. 이 과정에서 차원이 줄어들었다가 다시 증가하는 모델의 구조적 특성으로 인해 인코더는 데이터에서 중요한 핵심 특성만을 표현하도록 유도되고, 디코더는 압축된 정보만으로 원본 데이터를 잘 복원하도록 유도된다. 하지만 이러한 기존 Autoencoder는 임의의 잠재 벡터로부터 의미 있는 데이터를 생성하는 것이 어렵다는 한계점이 존재한다. 이는 학습 과정에서 등장하지 않은 영역의 데이터를 생성할 경우 비정상적인 출력이 생성되는 문제가 발생하기 때문이다.

이러한 문제를 해결하기 위해 등장한 VAE(Variational Autoencoder)는 기존 Autoencoder의 결정론적 잠재 공간을 확률론적 표현으로 확장한 모델로, Autoencoder와 동일하게 인코더와 디코더로 이루어져 있지만, 인코더는 입력 데이터를 잠재 공간의 확률 분포로 매핑하고, 디코더는 잠재 변수로부터 데이터를 복원하는 분포를 학습한다는 차이점이 있다 [6].



[그림 3] CVAE의 모델 구조

CVAE(Conditional Variational Autoencoder)는 기존 VAE를 확장한 모델로 기존 VAE가 조건 없이 데이터의 분포만을 학습하는 문제점을 개선하기 위해 조건 정보를 같이 입력받도록 설계되어 해당 조건에 부합하는 출력을 생성할 수 있다. 이를 통해 단순히 학습 데이터와 비슷한 데이터를 생성하는 것이 아니라 더 나아가 목적에 맞는 제어된 데이터의 생성을 가능하게 한다.

본 연구에서 모델의 목표가 단순히 데이터셋을 바탕으로 그럴듯한 아무 분자 구조를 생성하는 것이 아니라 화학적 물성 조건을 만족하는 분자 구조를 생성하는 것이 목표이기 때문에 물성 조건을 입력에 반영하기 위해 CVAE를 사용하였다 [7].

본 연구에서 설계한 모델인 MoleculeCVAE는 분자 그래프를 인코딩하는 그래프 기반 인코더인 GraphEncoder와 잠재 벡터 및 조건 정보로부터 결합 구조를 예측하는 transformer 기반 디코더인 MoleculeDecoder로 구성된 CVAE 구조이다. 인코더는 분자 그래프를 입력받아 분자의 잠재 공간의 확률 분포로 압축하고, 디코더는 잠재 벡터와 조건 벡터를 입력받아 원자 간 결합 구조를 예측하는 방식으로 동작한다. 잠재 공간(latent space)의 경우 128차원으로 설정하였으며, 인코더와 디코더 모두 256차원의 은닉층(hidden layer)을 가지고 있다.

조건 벡터는 물성 벡터 p와 원소 존재 여부 벡터 a_bin으로 구성된다. 물성 벡터는 앞에서 설정한 5가지 물성 HOMO, LUMO, HOMO-LUMO 갭, 총 에너지, 쌍극자 모멘트로 이루어져 있고, 학습 전 데이터셋 전체에 대해 z-score 정규화가 진행된 값이 사용된다. 원소 존재 여부 벡터 a_bin은 분자에 포함된 원소 종류를 나타내는 이진 벡터로, 앞에서 정의한 원소들인 C, H, O, N, S, P, F, Cl, Br, I의 존재 여부를 나타내게 된다. 추론 시에는 정확한 원소 개수를 알 수 없는 상태에서 예측을 수행해야 하므로 보조 예측 head인 a_pred_head를 통해 잠재 벡터 z, 물성 벡터 p, 원소 존재 여부 벡터 a_bin을 입력받아 원소의 개수를 예측하도록 설계하였다. 이 예측값은 추론 시 인코더의 원자 시퀀스 구성 과정에서 사용되고, 학습 시에는 a_pred_head의 출력값이 아닌 실제 원소 개수가 원자 시퀀스 구성에 사용된다. a_pred_head는 학습 과정에서 MSE loss를 통해 모델의 다른 레이어들과 함께 학습된다.

인코더(GraphEncoder)는 GINEConv(Graph Isomorphism Network with Edge features) 기반의 그래프 신경망으로 구현하였다. 그래프 신경망 중 하나인 GIN(Graph Isomorphism

Network)은 그래프 동형성을 바탕으로 한 모델로 기존 GNN 모델들 대비 서로 다른 그래프 구조를 구별하는 능력을 개선한 구조이고, GINEConv는 이웃한 노드의 특징뿐만 아니라 간선(edge)의 특징까지 함께 반영할 수 있도록 GIN을 개선한 모델이다. [8], [9], [10]. MoleculeCVAE의 인코더에서 다른 그래프 신경망이 아니라 GINEConv를 사용한 이유는 분자의 성질을 결정하는 데에 원자의 종류 뿐만 아니라 결합 차수나 방향족성과 같은 결합의 특성 또한 분자의 물리화학적 성질을 결정하는 핵심 요소이기 때문에 GIN의 강력한 구조 표현력을 유지하면서 엣지 특징을 잘 반영하는 GINEConv를 채택하게 되었다.

인코더에서는 원자의 노드 특성으로는 원소 임베딩(120→64차원), 형식 전하(1차원), 카이랄성(3차원)을 연결한 68차원의 벡터를 구성하였고, 이를 projection하여 초기 노드 표현 벡터를 얻었다. 각 결합의 엣지 특성으로는 결합의 종류(4차원), 결합 입체구조(5차원), 이면각(1차원)을 연결하여 10차원 벡터를 구성하였다. 이후 LayerNorm과 ReLU가 적용된 GINEConv 레이어를 4번 통과하여 각 원자의 은닉 표현을 계산하고, global_mean_pool로 모든 원자의 은닉 벡터의 평균을 통해 256차원의 분자 수준 표현 g 를 얻는다. 최종적으로 g 와 물성 조건 벡터 p , 원소 존재 여부 벡터 a_bin 을 연결한 271차원 벡터를 pool_proj MLP에 통과시켜 256차원의 분자 표현을 얻는다.

이후 잠재 공간(latent space)에서는 h 가 μ -head와 $\log \sigma$ -head를 통해 잠재 공간의 평균 μ 와 표준편차의 로그를 씌운 $\log \sigma$ 로 분리되고 $z = \mu + \sigma \cdot \epsilon$ 와 같이 reparametrization을 통해 잠재 벡터 z 를 샘플링하게 된다. 이때 reparametrization을 사용하는 이유는 평균이 μ 이고 표준편차가 σ 인 정규분포 $N(\mu, \sigma^2)$ 에서 잠재 변수 z 를 임의로 샘플링하는 과정에서 샘플링이라는 연산은 원래 미분이 불가능하여 기울기가 전달되지 못하는 문제가 발생하기 때문에 이를 해결하기 위해 미분이 가능하도록 수학적으로 분리하기 위해서이다 [6]. 디코더는 잠재 벡터 z 와 조건 벡터로부터 원자 쌍 간 결합의 존재 여부와 결합의 종류를 예측하는 구조이다. 조건 벡터 c 는 잠재 벡터 z , 물성 조건 벡터 p , 원소 존재 여부 벡터 a_bin 을 연결한 143차원의 벡터를 cond_proj MLP에 통과시켜 계산하고, 원자 시퀀스의 경우 각 원자에 대해 원소 임베딩을 적용한 후 조건 벡터 c 와 연결되어 init_proj MLP를 통해 256차원의 초기 원자 표현 벡터 h 를 생성하게 된다. 이때 원자 시퀀스는 분자 내에서 각 원소의 개수 정보로부터 구성되는데 추론이 진행되는 과정에서는 z , p , a_bin 을 연결한 143차원 벡터를 a_pred_head에 통과시켜 계산한 원소 개수 정보 예측값을 사용하고, 학습이 진행되는 과정에서는 실제 정답의 원소 개수를 직접 입력받아 사용한다. 이후 원자 표현 벡터 h 는 AdaLN이 적용된 Transformer 레이어 4개를 통과하여 원자쌍 특성들을 얻게 되고, 이를 각각 bond_exist MLP와 bond_type MLP에 통과시켜 각각 결합이 존재할 확률과 결합의 종류를 예측한다. 결합 존재 예측에서는 BCE Loss를 적용하고, 결합 종류 예측에서는 CE Loss를 적용한다.

이러한 VAE 기반의 모델의 손실함수는 아래와 같이 크게 2가지 항으로 구성된다. 이때 β 는 KL Divergence에 곱해지는 하이퍼파라미터로 β 가 1보다 커지면 잠재 벡터가 정규분포와 가까워지게 되어 모델이 데이터 내에서 더욱 핵심적이고 독립적인 특징을 잠재 공간의 각 차원마다 분리하여 학습하게 유도하고, β 가 1보다 작아지면 복원에 더 집중하여 출력 데이터의 품질이 올라가지만 잠재 공간이 정규분포를 따르지 않아 생성 성능이 저하될 수 있다. 일반적인 VAE는 학습 초반에는 인코더가 입력 데이터를 잠재 공간에 제대로 압축하지 못하기 때문에 모델이 복원 성능을 향상시키지 않고 KL Divergence만을 줄이게 되어 잠재 공간이 붕괴되는 현상이 발생하게 된다. 이에 따라 β 의 값을 학습 과

정 전반에서 적절하게 조절해주는 scheduling이 필요해지게 되었다.

그래서 β schedule은 cyclical cosine annealing 방식을 채택하였다. 전체 학습 구간을 n 개의 사이클로 나누어 각 사이클의 앞쪽 ratio 비율에 해당하는 구간에서는 β 를 0에서 $\beta_{\max}$ 까지 cosine 함수로 증가시키고 나머지 구간에서는 $\beta_{\max}$ 로 고정한다. 이는 다음과 같이 계산된다.


$$t = \frac{\text{cycle pos}}{\text{cycs steps} \times \text{ratio}}, \quad \beta(t) = \beta_{\max} \times \frac{1 - \cos(\pi t)}{2}$$

본 연구에서는 $n=4$, $\text{ratio}=0.5$, $\beta_{\max}=0.5$ 로 설정하였다. 이는 사이클마다 β 가 0으로 리셋되어 인코더가 재구성에 집중하여 학습할 수 있도록 반복적으로 유도함으로써 잠재 변수가 데이터의 유의미한 정보를 담지 못하고 무시되는 posterior collapse를 방지한다.

모델 학습을 테스트하는 과정에서 cyclical cosine annealing만을 적용할 경우, 학습 초기 10 epoch 동안 모델이 β 의 상승으로 인해 KL-Divergence를 감소시키는 것에만 집중하여 인코더와 디코더가 잠재 표현을 제대로 학습하지 못하는 것을 확인하였다. 이를 해결하기 위해 학습 초기 warmup epochs 동안은 β 를 0으로 고정하여 모델을 일반 autoencoder처럼 학습하는 Beta Warm-up을 적용하였다. 이를 통해 인코더와 디코더가 KL-Loss로 인한 패널티의 영향 없이 의미 있는 잠재 표현을 우선적으로 학습하도록 유도하였다. 본 연구에서는 warmup_epochs를 10으로 설정하였다. 이때 $\beta=0$ 인 경우 KL-Loss가 없기 때문에 $\log \sigma$ 가 제한 없이 증가하는, 표본편차가 발산하는 문제가 발생할 수 있다. 이를 방지하기 위해 아래와 같이 $\beta=0$ 으로 유지되는 warm-up 구간에서는 reparametrization 없이 μ 를 잠재 벡터로 직접 사용하도록 구현하였다.

$$z = \begin{cases} \mu & (\beta=0) \\ \mu + \sigma \cdot \epsilon & (\beta>0) \end{cases}$$

이에 따라 학습 과정에서 β 는 아래와 같이 변화한다.



<그래프 1> beta cyclical cosine annealing

또한 모델 학습 결과를 통해 Beta Warm-up 만으로는 posterior collapse를 방지하기에 부족하다는 것을 확인한 후 이를 방지하기 위해 Free Bits KL을 적용하였다. 기존 KL은 잠재 벡터의 각 차원에 대해 다음과 같이 계산된다.

$$KL_d = -\frac{1}{2}(1 + 2\log\sigma_d - \mu_d^2 - \sigma_d^2)$$

여기에서 Free Bits KL은 각 차원의 KL에 하한을 λ 로 설정하여, KL이 λ 미만인 차원에 대해서는 패널티를 부과하지 않는다 [11].

$$L_{KL} = \frac{1}{B} \sum_{b=1}^B \sum_{d=1}^D \max(KL_{b,d}, \lambda)$$


본 연구에서는 $\lambda=0.1$, $D=128$ 로 설정하였다. 이에 따라 KL-Loss는 12.8을 최솟값으로 가지게 된다. 실제 학습에서도 warm-up 이후 KL-Loss가 12.8 수준에서 안정적으로 유지되고,

posterior collapse 없이 잠재 공간이 학습되고 있음을 확인하였다.

기존 Transformer에서 잠재 벡터 z 는 `init_proj`를 통해 원자 표현에 한 번만 주입된 후, 각 레이어의 LayerNorm이 이 표현을 정규화하는 과정에서 z 의 신호가 점점 희석되는 문제가 발생한다. 이를 해결하기 위해 AdaLN(Adaptive Layer Normalization)을 도입하였다 [12]. LayerNorm이란 각 레이어에 들어온 입력 데이터의 스케일을 조정하는 방법으로 평균과 분산을 맞추는 정규화를 수행하여 학습을 안정화하게 되는데, AdaLN은 이러한 LayerNorm에서 사용되는 스케일(Scale, γ)과 시프트(Shift, β) 파라미터를 고정된 상태로 두는 것이 아니라 외부 조건인 잠재 벡터 z 로부터 실시간으로 생성하여 적용하는 방식이다. 이를 적용함으로써 z 의 신호가 희석되어 디코더가 z 를 무시하고 `a_bin` 조건만으로 결합 패턴을 예측하는 문제를 매 레이어마다 잠재 벡터 z 의 스케일과 시프트를 독립적으로 계산하여 레이어 전체의 z 의 신호를 유지시키는 방식으로 해결하였다.

디코더의 원자 시퀀스는 원소 종류 순서로 정렬되어 있기 때문에 동일한 원소에 대한 원자들은 임베딩 벡터가 동일해져 Transformer가 같은 원소의 원자들을 구별하지 못하는 문제가 발생한다. 이를 해결하기 위해 학습가능한 위치 임베딩을 도입하였다.


아래 그림이 앞에서 설명한 MoleculeCVAE를 모식화한 구조도이다.



[그림 4] MoleculeCVAE 모델 구조

나. 학습 결과 분석


설계한 MoleculeCVAE를 전처리를 진행한 데이터셋 중 10만개만 랜덤 샘플링하여 학습을 진행하였다.




<그래프 2> 모델 학습 Loss

모델 학습을 진행한 후 Loss를 분석해 보았다. 위 그림을 통해 알 수 있듯이 beta가 cyclical cosine annealing에 의해 변화 함에 따라 Loss에 KL-Loss가 반영되는 비율이 변화하여 최종 Loss도 beta의 변화를 비슷하게 따라가는 모습을 확인할 수 있다.

reconstruction loss도 train과 validation에서 모두 지속적으로 수렴하는 것을 확인할 수 있었다. 이를 통해 모델이 posterior collapse에 빠지지 않고 잠재 표현을 제대로 학습하고 있다는 것을 알 수 있다.



<그래프 3> threshold에 따른 validity



<그래프 4> threshold에 따른 uniqueness

위 그래프는 threshold에 따른 validity와 uniqueness를 각각 epoch 50, 60, 70에서 분석해 본 결과이다. 예상대로 threshold를 높일수록 validity가 증가하고, uniqueness가 감소하는 것을 확인할 수 있었다. 다만 epoch 60, epoch 70 모델이 epoch 50인 모델보다 동일 threshold에서 더 낮은 validity를 기록하였다. 이는 학습이 진행될수록 모델이 결합 존재 여부에 대해 더 확인 있는 예측을 하게 되는 것과 관련이 있는데, 초기 epoch에서는 bond_exist 예측값이 0.5 주위에 분포하는 경향이 있어 동일한 threshold에서 상대적으로 적은 수의 결합만 선택되는 반면, 학습이 진행될수록 예측값이 0과 1 양 극단으로 분리되면서 threshold 0.7을 기준으로 더 많은 결합이 선택된다. 이러한 경우에는 일부 원자에 과도한 결합이 형성되어 원자가 규칙을 위반하는 분자가 생성되는 문제가 발생할 수 있다. 또한 cyclical beta scheduling의 영향도 있다. epoch 50은 2번째 β 사이클에서 β 가 0.5로 유지되는 flat 구간에 해당하는 반면 epoch 60은 3번째 β 사이클이 시작되어 β 가 0으로 초기화된 직후의 ramp 구간에 해당한다. β 가 낮은 구간에서는 KL-Loss에 의한 패널티가 약화되어 인코더가 z 에 더 많은 구조 정보를 담을 수 있게 되고, 디코더가 이를 활용해 더욱 적극적으로 결합을 예측하게 된다. 이러한 이유들로 인해 동일 threshold에서 더 많은 결합이 선택되어 오히려 validity가 낮아지는 현상이 나타난 것으로 분석하였다. 하지만 학습 결과를 통해 이 구조의 한계점 또한 확인할 수 있었다. 인코더의 global_mean_pool은 permutation-invariant 집약 연산으로 원자별 구조적 명확성을 단일 잠재 벡터 z 로 압축하며, 이 과정에서 원자 쌍 결합에 대한 위치 정보가 손실되게 된다. 이로 인해 디코더는 결합 존재 여부를 예측하는 과정에서 원자 종류에 대한 통계적 특성에만 의존하게 되고, 분자 구조를 담은 잠재 벡터 z 로부터 복원을 제대로 수행하지 못하게 된다. 더 나아가 BCE 기반의 엣지 예측은 각 원자 쌍을 조건부 독립으로 취급하기 때문에 화학적 원자가 제약을 loss에 반영하지 못한다. 결과적으로 학습이 진행되면서 결합 확률 분포가 bimodal하게 분리되게 되며 reconstruction loss의 개선이 validity의 개선으로 이어지지 않는 문제가 발생하게 된다.

3. 2차 모델 (Molecule Graph Diffusion)

가. 1차 Diffusion 모델 (Uniform Noise)

1차 모델의 결론에서도 확인했듯이, Graph CVAE는 구조적 한계로 인해 화학적 유효성인 validity가 학습이 진행되어도 개선되지 않는 모습을 보였다. 이는 Graph CVAE의 구조적 문제인 global_mean_pool로 인한 구조 정보 붕괴, BCE 기반 손실로 인한 원자가 제약 없는 결합 예측에 의한 것으로 분석할 수 있었고, 이러한 구조적 문제는 손실 함수의 개선이나 모델 하이퍼파라미터의 조정으로 해결하기 어렵다고 판단하였다. 이에 따라 분자 그래프 전체를 하나의 벡터로 압축하지 않고, 여러 step에 걸쳐 점진적으로 그래프 구조를 복원하는 Diffusion 기반의 모델로 전환하게 되었다.

Diffusion 모델은 원본 데이터에 점진적으로 노이즈를 추가하는 forward process와 노이즈로부터 원본을 복원하도록 학습하는 reverse process로 구성된다. 이미지 등 연속값 데이터에서는 가우시안 노이즈를 사용하지만, 분자 그래프의 원자 종류, 결합 종류는 범주형 데이터이기 때문에 가우시안 노이즈를 적용할 경우 그래프의 희소성이 파괴되고 연결성, 고리 개수와 같은 그래프의 정보가 제대로 정의되지 않는 문제가 발생한다. 이에 본 연구에서는 DiGress(Discrete Denoising diffusion for graph generation)을 참고하여 이산 카테고리 변수에 대한 Discrete Diffusion을 채택하였다 [13].


Discrete Diffusion은 카테고리 변수 x 가 d 개의 클래스를 가질 때, 전이 확률 행렬 Q_t 를 이용해 $q(x^t|x^{t-1})=x^{t-1}Q_t$ 로 정의된다. 여러 step에 걸친 전이는 누적 행렬 $\overline{Q^t}=Q^1Q^2\cdots Q^t$ 로 한 번에 계산할 수 있어 $q(x^t|x_0)=x_0\overline{Q^t}$ 로 임의의 시점 t 의 노이즈 상태를 즉시 샘플링할 수 있다. 역과정은 사후분포 $q(x^{t-1}|x^t,x_0)\propto x^t(Q^t)^T\odot x_0\overline{Q^{t-1}}$ 를 신경망이 예측한 $\hat{p}(x_0|x^t)$ 로 근사하여 샘플링한다.

전이행렬은 가장 단순한 형태인 균등분포로 설정하였다.

$$Q^t=\overline{\alpha^t}I+(1-\overline{\alpha^t})\frac{11^T}{d}$$

$\overline{\alpha^t}$ 는 cosine schedule을 사용하였고, 노드와 엣지에 대해 각각 CrossEntropy Loss를 계산하고, 신경망은 Graph Transformer(GTLayer) 구조를 사용하였다.

아래 그림이 앞서 설명한 Discrete Diffusion 기반 분자 생성 모델을 모식화한 구조도이다.



[그림 5] MoleculeGraphDiffusion 모델 구조

수소를 포함한 QMugs 전체 데이터로 186 epoch 학습한 결과, validation loss는 1.32에서 0.79로 꾸준히 감소하였으나 validity는 최대 0.8%, 대부분 0.0%에 머물렀다. 원자 타입 예측 손실(T-x)은 약 0.72 수준에서 정체되었는데, 이는 항상 탄소만 예측하는 경우의 손실 값 약 0.69와 거의 일치하는 값으로 모델이 원소 타입을 실질적으로 구별하지 못하고 있음을 확인할 수 있었다.

QMugs는 ChEMBL에서 추출한 drug-like 분자로 구성되어 있으며, 탄소 골격 위에 질소, 탄소, 황, 할로젠 등의 헤테로원자가 관능기를 이루는 구조이다. 실제 약효를 결정하는 것은 골격 자체가 아니라 이 헤테로원자의 종류와 위치이기 때문에 모델이 단순히 탄소만 예측한다면 이는 곧 분자를 실질적으로 구별하는 화학적 정보를 학습하지 못했다는 것을

의미한다. 즉, 단순히 loss가 감소했다고 해서 화학적으로 유의미한 결과를 기대하기 어려운 것이다.

이의 원인으로 두 가지를 분석해보았다. 첫 번째는 수소 명시의 비효율성이다. QMugs 분자에서 수소는 전체 원자의 50~60%를 차지한다. 그러나 유기화학의 원자가 이론에 따르면 탄소는 4개, 질소는 3개, 산소는 2개의 결합을 형성할 수 있기에, 이미 형성된 결합 수를 알고 있다면 남은 결합자리는 전부 수소로 채워도 된다. 즉 수소를 그래프에 명시적으로 포함시키는 것은 원자가로부터 계산할 수 있는 정보를 불필요하게 모델에서 예측하도록 강제하고 있는 것이다. 이는 분자 그래프의 크기를 2배 이상으로 불필요하게 늘려 학습의 난이도를 증가시키고, 정작 화학적으로 의미 있는 헤테로원자 예측에 사용되어야 할 모델의 용량을 잠식하게 된다. 이에 따라 수소를 후처리 과정에서 원자가로부터 자동 복원하는 방식을 적용하였다. 두 번째는 노이즈 오차 누적이다. 코사인 스케줄에서 노이즈의 강도는 절대적인 step 수가 아닌 비율로 정의된다. 즉 T=500에서 T=250과 T=150에서 T=75는 수학적으로 동일한 노이즈 강도를 의미한다. 따라서 학습이 표현하는 노이즈 분포 자체에는 영향을 주지 않으면서 T를 줄일 수 있다. 이러한 점을 활용해 Reverse process에서 매 step 발생하는 오차의 누적으로 인한 영향을 줄이기 위해 오차 누적 경로를 단축할 수 있도록 T=500에서 T=150으로 축소하였다.

나. Absorbing Diffusion

1차 Diffusion 모델에서의 uniform noise의 근본적인 문제를 분석한 결과 여러 문제점을 발견할 수 있었다. 먼저 RDKit의 SanitizeMol이 결합이 전혀 없는 고립 원자 나열을 유효한 분자로 판정하는 문제로 인해 모델이 결합을 예측하지 않고 loss를 낮춰 validity를 높이는 잘못된 shortcut이 형성되는 문제이다. 이로 인해 학습이 진행될수록 오히려 결합이 없는 분자로 수렴해나가는 경향을 보였다. 또다른 문제는 엣지 클래스 불균형이다. 분자 그래프를 표현한 인접 행렬에서 실제 결합은 5% 미만이며, 나머지는 결합이 없는 상태였다. 또한 노드와 엣지의 gradient 불균형으로 엣지의 손실이 전체 gradient를 독점하여 노드의 학습이 약화되는 문제도 존재하였다.

이를 해결하기 위해 노이즈를 균등분포가 아닌 오직 하나의 흡수 상태, 즉 [MASK] 토큰으로만 주입하는 방식인 Absorbing Diffusion으로 전환하였다. 이를 위해 K개의 실제 클래스에 [MASK] 클래스를 추가하여 K+1차원으로 확장하고, 시간 t에서 원래 토큰이 [MASK]로 변할 전이 확률을 $q(x^t = \text{MASK} | x_0 = c) = 1 - \alpha^t$ 로 정의하였다. 이를 통해 한번 복원된, 즉 [MASK]가 아닌 토큰이 이후 단계에서 다시 [MASK]로 변하지 않게 된다. 또한 결합을 끊어 validity를 올리는 shortcut을 막기 위해 생성된 분자의 최대 연결 성분 비율이 85% 미만일 경우 무효 처리하는 필터를 추가하였고, 클래스 불균형 보정을 위한 역빈도 가중치를 노드와 엣지 손실에 각각 적용하였다.

이렇게 이전 모델의 문제점들을 개선하였고, 새롭게 설계한 모델로 학습을 진행하였다. 하지만, 26 epoch 동안 validity가 0%로 나타나 추가적인 분석을 진행하였다.

다. 성능 저하 원인 분석 및 가설 검증

성능 저하의 원인을 파악하기 위해 소분자로 이루어진 toy 데이터셋을 이용해 모델이 데이터를 제대로 overfit 할 수 있는지를 파악하였다. 만약 이러한 작은 문제도 해결하지 못

한다면 구조적인 결함이 존재한다는 것이고, 해결할 수 있다면 모델의 규모와 분자 생성의 난이도의 문제라는 것을 의미한다.


우선 원자와 결합의 예측 정확도를 측정하였다. 이 둘을 분리하여 측정하기 위해 분자의 일부만 마스킹하여 마스킹된 위치에 대한 조건부 예측 정확도를 마스크 비율별로 측정하는 방식을 사용하였다.

<표 4> 마스크 비율에 따른 원자/결합 정확도

마스크 비율	원자 정확도	결합 정확도	결합 없음 정확도
10%	1.000	0.727	0.833
30%	0.893	0.615	0.891
50%	0.784	0.482	0.851
90%	0.770	0.149	0.958

원자 예측은 마스크 10% 조건에서 100%의 정확도를 보이며 원자 class 불균형은 주요 원인이 아니라는 것을 확인하였다. 반면 결합 예측은 73% 수준의 정확도를 보이면서 마스크 비율이 증가할수록 정확도가 급격하게 하락하는 모습을 보였다. 즉 모델이 원자보다는 결합 예측에서 문제가 발생하고 있음을 알 수 있다.

이후 모델의 결합 예측 성능을 보강하기 위해 아키텍처를 수정하였다. 기존 Graph Transformer의 엣지 업데이트는 $h_i + h_j$ 와 같이 두 원자 표현의 합을 사용하는 구조였다. 이러한 덧셈은 대칭성을 보장하지만, 특정 원자 쌍이 결합하는지를 판별하는 데 필요한 곱 신호가 없어 결합 예측력이 약했다.



<그래프 5> 엣지 상호작용 항 추가 전후 validity 비교


이에 곱 항 $h_i \odot h_j$ 를 추가하고 엣지 표현 차원을 64에서 128로 확장하였다. 이를 같은 분자로 재검증한 결과 validity가 수정 전 20.8% 대비 54.2%로 크게 개선된 것을 확인하였다. 이를 통해 결합 예측 아키텍처의 구조적 결함이 핵심 문제였음을 확인할 수 있었고, 곱 항 추가만으로 큰 개선을 얻을 수 있었다.

라. Noise Model 재설계

선행 논문에서도 본 연구와 동일한 문제를 확인했다는 것을 알 수 있었다. 그래프는 본질적으로 희소하기 때문에 균등분포로 노이즈를 주면 노이즈 상태의 marginal 분포가 실제 데이터 분포와 크게 달라 학습이 어려워진다는 점이였다. DiGress 논문에서는 이를 노이즈가 수렴하는 분포를 균등분포나 특수 마스크 분포가 아니라 $Q^t = \alpha^t I + \beta^t 1m^T$ 와 같이 학습 데이터의 실제 클래스 marginal 분포로 설정하여 개선하였다. 이를 참고하여 본 연구에 적용해보았다.

이 경우 완전 노이즈 상태에서도 그래프는 어느정도 희소한 상태를 유지하므로, 모델이 아무 정보가 없을 때에는 기본값이 no_bond라는 사전 정보를 노이즈 구조로부터 자연스럽게 습득할 수 있다.


이렇게 수정된 모델을 검증하기 위해 24개의 소분자로 이루어진 toy 데이터셋을 제작하였고, baseline과 동등한 수준인 49%를 달성한 것을 확인하였다.




<그래프 6> Noise Model에 따른 validity 비교

다만 이 toy 데이터셋은 결합 밀도가 높아 희소성 반영의 이점이 제대로 검증되지 않았을 수 있다고 생각하여 실제 약물 분자로 재검증을 수행하였고, Absorbing Mask는 2.4%, Marginal transition은 9.5%를 달성하며 희소성이 실제 데이터에 가까워짐에 따라 marginal이 약 4배 우세한 모습을 보였다.

이것이 실제 QMugs 규모의 데이터셋에서도 재현되는지 확인하기 위해 QMugs 학습 데이터 중 8000개를 샘플링한 subset, 40 epoch 조건으로 Absorbing 방식과 Marginal transition 방식을 각각 학습하였다.



<그래프 7> Absorbing 방식 학습 loss



<그래프 8> Marginal transition 방식 학습 loss


두 방식 모두 원자, 결합 loss (T-x, T-e)가 안정적으로 감소하였고, train/val 사이에 과적합 징후도 보이지 않았다. 그러나 validity는 두 방식 모두 0~0.4% 수준으로 사실상 개선이 없었다. 이는 1차 Diffusion에서와 동일하게 loss 감소가 validity의 개선으로 이어지지 않는 문제이다. 아키텍처 수정과 noise model 개선 모두 toy 규모에서는 뚜렷한 개선을 보였음에도 실제 규모에서의 개선이 없다는 것은 더욱 근본적인 원인이 존재한다는 것을 의미했다. 이에 모델 구조가 아닌 데이터 표현 자체의 문제를 분석하게 되었다.

마. 방향족 결합 표현 문제

모델의 아키텍처 개선과 noise model 개선에도 불구하고 실제 QMugs 데이터에서 validity가 지속적으로 낮게 관측되어 모델 구조의 문제가 맞는지 확인하기 위해 완벽한 모델이 학습 데이터 분포를 정확히 재현했다고 가정할 때 이론적으로 도달 가능한 validity의 상한을 측정하는 Ground-Truth 재구성 검증을 진행하였다.

이를 위해 실제 QMugs 학습 데이터 중 500개의 분자를 모델의 예측 없이 노이즈도 거치지 않고 학습에 사용되는 것과 동일한 텐서 변환을 거친 뒤 해당 텐서 그대로 RDKit 분자로 재구성하여 화학적 유효성을 확인하였다. 그 결과 80.2%의 validity를 보였다. 이는 모델이 아무리 완벽히 학습되더라도 validity가 100%가 아닌 80% 근처에서 이론적으로 제한된다는 것을 의미한다. Validity 계산을 SanitizeMol 통과 여부로 진행했기 때문에 SanitizeMol을 통과하지 못하는 분자들의 실패 원인을 분석한 결과 KekulizeException이 18%, AtomValenceException이 1.8%를 차지했다.

이에 대한 근본적 원인으로 가장 먼저 세운 가설은 전처리 과정에서 결합 차수를 분류할 때 방향족을 독립된 클래스로 인코딩한 것이 문제라는 것이었다. 이는 그래프 생성 모델이 각 결합, 즉 엣지를 독립적으로 예측하는데, 방향족이라는 성질은 개별 결합 하나만으로는 결정할 수 없는 전역적인 속성이기 때문에 모델이 각 결합을 독립적으로 방향족이라고 예측하더라도 그 예측들이 모였을 때 정확히 하나의 유효한 고리를 형성하지 못하면 RDKit의 케쿨화 탐색이 실패하여 분자 전체가 유효하지 못한 상태가 된다. 이러한 점에서 방향족을 독립적인 클래스로 두는 것이 아닌, 국소적인 정보를 담고 있는 단일 결합과 이중 결합의 교대 패턴으로 표현하는 Kekulize 연산을 적용하였다.



<그래프 9> 결합 표현 방식에 따른 이론적 validity 상한

이를 적용한 모델의 화학적 유효성을 평가한 결과 96.2%의 validity로 기존 대비 16% 향상된 성능을 보였다. 이를 통해 16%의 validity가 방향족을 독립된 클래스로 두는 표현 방식에서 발생한 손실이었다는 것을 정량적으로 확인할 수 있었고, 방향족이라는 성질이 개별 결합을 독립적으로 예측하는 그래프 생성 모델에서 적합하지 않다는 가설을 검증할 수 있었다.

1. 결론 및 기대효과

본 연구는 물성 조건으로부터 분자 결합 구조를 생성하는 딥러닝 모델을, One-shot 방식 (Molecule Graph CVAE)에서 시작하여 Discrete Graph Diffusion 방식으로 발전시켰다.

1차 모델에서는 QMugs 데이터셋을 활용하여 HOMO 에너지, LUMO 에너지, HOMO-LUMO 갭, 전체 에너지, 쌍극자 모멘트의 5가지 물성을 조건으로 입력을 받아 분자 내 원자 간 결합 구조를 예측하는 CVAE 기반 모델을 설계하였고, 학습 과정에서 reconstruction loss와 KL-Loss가 수렴하여 모델이 분자 그래프의 구조적 특성을 일정 수준 학습하고 있음을 확인할 수 있었다. 다만 One-shot 방식의 구조적 한계로 인해 화학적 유효성 만족의 측면에서 구조적 개선이 필요하다라는 점을 확인하였고, 이에 따라 Diffusion 기반의 2차 모델 설계 방향을 설정하였다.

2차 모델에서는 1차 모델에서 확인된 구조적 한계를 근거로 Diffusion으로 전환하였고, Diffusion 내부에서도 uniform에서 absorbing mask, marginal transition으로 noise model을 재설계하였다. 이 과정에서 방향족 표현을 독립된 클래스로 표현하는 것이 모델 성능에 악영향을 미칠 수 있다는 것을 발견하였다. 즉, 방향족 표현을 독립된 클래스로 두는 것이 화학적으로는 직관적일 수 있으나, 생성 모델이 학습하기 좋은 표현은 이와 다를 수 있다는 것이다. 이러한 점에서 방향족을 개별적인 단일 결합과 이중 결합으로 나타내도록 하는 kekulize를 적용하였다. 다만 이 시점에서 kekulize를 반영한 실제 QMugs 규모에서의 최종 validity는 아직 검증되지 않았다. 즉, 현재까지는 왜 분자 생성이 실패했는가에 대한 가설 중 하나를 확인한 상태이며, 이것을 개선하였을 때 최종적으로 분자 생성 성능이 증가하는지는 추가적인 확인이 필요할 것이다.

본 연구에서 개발하고자 하는 모델이 연구 목표를 달성한다면 신약 개발 및 신소재 개발 과정에서 목표하는 물성을 가진 분자의 후보를 기존의 무작위 탐색 방식 대비 훨씬 효율적이고 빠르게 얻을 수 있을 것이다. 이를 통해 신약 개발이나 신소재 개발 등에 소요되는 시간과 비용을 획기적으로 절감할 수 있을 것이다.

2. 향후 발전 방향

가장 우선적인 과제는 kekulize가 반영된 데이터로 실제 QMugs 데이터셋 규모에서 diffusion 모델의 validity를 재검증하는 것이다. 지금까지의 분석은 통제된 로컬 환경에서 소규모 데이터를 사용해 가설을 검증한 결과이며, 이러한 개선이 실제 규모의 데이터에서도 동일한 폭으로 validity의 개선을 가져올 수 있는지는 아직 확인되지 않았다. 이에 따라 kekulize가 반영되어 재전처리된 QMugs 전체 데이터셋을 이용하여 marginal transition noise model과 엣지 상호작용 항이 수정된 구조를 실제 규모에서 재학습하고, 그 결과로 나타나는 validity를 검증할 것이다.

또한 구조적 특징을 추가로 도입하는 방안을 검토할 것이다. 현재 모델은 원자와 결합의 종류만을 입력으로 사용하고 있으나, 매 denoising 단계마다 그래프 상태에서부터 각 원자의 현재 원자가나 분자량 등을 재계산하여 입력에 추가하면 모델이 화학적 제약을 더 직접적으로 학습할 수 있을 것으로 기대된다. 이러한 구조적 특징의 추가가 validity 개선에 실질적으로 기여하는지를 실험을 통해 확인할 것이다.

다음으로는 물성 조건을 실제로 반영하는 conditioning 구조를 설계할 것이다. 현재까지의 diffusion 모델은 노이즈로부터 결합 구조를 복원하는 생성 코어의 검증에 집중하였기 때문에, 물성 조건 벡터를 입력받지 않는 비조건부 생성 모델로 구현되어 있다. 생성 코어의 validity가

안정적으로 확보되는 대로, classifier-free guidance와 같은 기법을 도입하여 물성 조건이 실제로 생성되는 분자 구조에 반영되도록 조건부 생성 구조를 설계하고 학습할 것이다.

조건으로 사용하는 물성의 종류를 다양화하는 작업 또한 필요하다. 현재는 QMugs 데이터셋에서 제공하는 HOMO 에너지, LUMO 에너지, HOMO-LUMO 갭, 전체 에너지, 쌍극자 모멘트의 5가지 물성만을 조건으로 사용하고 있다. 그러나 본 연구가 최종적으로 목표하는 것은 신약 후보 물질과 같이 특정 용도에 적합한 분자를 생성하는 것이므로, QED나 합성 가능성, Lipinski's Rule of Five와 같은 약물유사성 지표를 조건으로 추가하는 방향을 고려할 것이다. 나아가 QMugs 외의 여러 데이터셋을 함께 활용하여 더 다양한 물성과 더 넓은 범위의 분자 구조를 학습할 수 있도록 데이터셋을 확장하는 것도 병행할 것이다.

마지막으로 장기적으로는 3차원 분자 구조로의 확장을 고려하고 있다. 현재 모델은 원자 간 결합의 종류를 나타내는 2차원 그래프까지만을 생성하며, 실제 3차원 좌표는 별도의 계산화학 도구를 통해 얻어야 한다. 전처리 과정에서 이미 각 conformer의 3차원 좌표 정보를 함께 저장해두었으므로, 이를 활용하여 E(3)-equivariant diffusion과 같은 방식으로 결합 구조와 3차원 좌표를 동시에 생성하는 모델로 확장하는 것을 추가적인 과제로 하고자 한다.

- [1] Cura Precision Biomedical 및 KHIDI 미국지사, “신약 연구 개발 과정 개요 및 최신 미국 동향,” 한국보건산업진흥원, 충북 청주시, 보건산업브리프 Vol. 376, 2022.
- [2] 장상연, 최익주, “지능형 영상분석 기술의 보안 및 관제 분야 활용 동향,” 한국정보통신학회논문지, 제24권 제3호, pp. 415-422, 2020년 3월. doi: 10.6109/jkiice.2020.24.3.415.
- [3] C. Isert, K. Atz, J. Jiménez-Luna, and G. Schneider, “QMugs: Quantum mechanical properties of drug-like molecules,” arXiv preprint arXiv:2107.00367, 2021.
- [4] R. van Deursen, L. C. Blum, and J.-L. Reymond, “A Searchable Map of PubChem,” J. Chem. Inf. Model., vol. 50, no. 11, pp. 1924-1934, Nov. 2010, doi: 10.1021/ci100237q.
- [5] C. Isert, K. Atz, J. Jiménez-Luna, and G. Schneider, “QMugs, quantum mechanical properties of drug-like molecules,” Sci. Data, vol. 9, no. 1, p. 273, Jun. 2022, doi: 10.1038/s41597-022-01390-7.
- [6] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” in Proc. 2nd Int. Conf. Learn. Represent. (ICLR), Banff, AB, Canada, 2014. [Online]. Available: <https://arxiv.org/abs/1312.6114>
- [7] D. P. Kingma, S. Rezende, D. J. Rezende, and M. Welling, “Semi-supervised learning with deep generative models,” in Proc. 27th Int. Conf. Neural Inf. Process. Syst. (NIPS), Montreal, QC, Canada, 2014, pp. 3581-3589.
- [8] T. N. Kipf and M. Welling, “Variational graph autoencoders,” arXiv preprint arXiv:1611.07308, 2016.
- [9] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, “How powerful are graph neural networks?,” in Int. Conf. Learn. Represent. (ICLR), 2019.
- [10] W. Hu, B. Liu, J. Gomes, M. Zitnik, P. Liang, V. Pande, and J. Leskovec, “Strategies for pre-training graph neural networks,” in Proc. Int. Conf. Learn. Represent. (ICLR), 2020.
- [11] D. P. Kingma, T. Salimans, R. Jozefowicz, X. Chen, I. Sutskever, and M. Welling, “Improved variational inference with inverse autoregressive flow,” in Advances in Neural Information Processing Systems, vol. 29, 2016.
- [12] W. Peebles and S. Xie, “Scalable Diffusion Models with Transformers,” in Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2023, pp. 4172-4182.

[13] C. Vignac, I. Krawczuk, A. Siraudin, B. Wang, V. Cevher, and P. Frossard, “DiGress: Discrete denoising diffusion for graph generation,” in Proc. Int. Conf. Learn. Represent. (ICLR), 2023.

VI

부록

모델 소스코드: <https://github.com/airhood/molecule-ai>