
조건부 확률 분포를 통한 시계열 데이터에서의 자기독립성 분석

1. 주제 선정 이유

인공지능의 동작 원리에 대해 공부하던 중 인공지능의 학습은 방대한 데이터로부터 학습 알고리즘을 통해 독립변수 x 와 종속변수 y 사이의 관계를 표현할 수 있는 함수 $f(x)$ 를 찾는 과정이라는 것을 알게 되었다. 따라서 인공지능의 추론 또한 데이터를 기반으로 하는 통계적 추론으로 볼 수 있고, 데이터 사이의 관계를 표현하는 $f(x)$ 를 완벽히 표현하는 것이 아닌 근사하여 표현하기 때문에 그 결과 또한 ‘독립변수 x 에 따라 y 가 어떠한 값일 확률’의 형태로 나타남을 알게 되었다. 이때 특정 사건은 예측이 쉽고, 특정 사건은 예측이 어렵다는 점에서 아이디어를 얻어 예측한다는 것이 무엇이며, 예측 가능하다는 것이 무엇인지를 통계적인 관점에서 분석해보게 되었다.

2. 이론적 배경

두 사건이 독립이라는 것은 한 사건의 발생이 다른 사건의 발생 확률에 영향을 주지 않는다는 것을 말한다. 이를 조금 더 수학적으로 표현해본다면 조건부 확률을 이용해서

$$P(B | A) = P(A | B)$$

로 표현할 수 있다.

동전 던지거나 주사위 굴리기 같은 것들이 대표적인 독립사건의 예시이다. 이 사건들은 서로에게 영향을 주지 않는다. 동전을 던졌을 때 앞면이 나왔다고 해서 그 다음에 주사위를 굴렸을 때 1이 나올 확률이 달라지지는 않는다.

이러한 동전 던지거나 주사위 굴리기 같은 사건들은 시간적으로 나뉘어진 사건들로 보아도 독립성을 띄고 있다. 예를 들어 t 초에 동전을 던지는 사건을 A_t 라고 한다면 $A_1 \sim A_T$ 모두 서로 독립일 것이다. 즉, 이전에 동전을 던진 결과가 다음 동전을 던졌을 때의 결과에 영향을 미치지 않는다는 것이다. 이러한 것을 ‘자기독립’이라고 한다.

상호정보량이란 두 변수 사이의 상호 의존성을 측정한 것으로 다른 무작위 변수를 통해 하나의 무작위 변수에 대해 얻은 정보의 양을 나타내며, 이 정보의 양의 평균값이 상호 정보량이다. [1]

이때 이산 확률 변수 X 와 Y 의 상호정보량은 아래와 같이 표현이 가능하다.

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} p(x,y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right)$$

예를 들어 만약 X 와 Y 가 서로 독립이라면 X 와 Y 가 서로 아무런 연관이 없기 때문에 X 를 통해 Y 에 대해 얻은 정보도 없을 것이고, Y 를 통해 X 가 얻은 정보도 없을 것이다. 따라서 상호정보량은 0이어야 한다. 이를 실제 식으로 계산해보게 되면 아래와 같이 동일하게 상호정보량이 0임을 알 수 있다.

X 와 Y 가 독립이라면

$$p(x,y) = p(x)p(y)$$

를 만족한다. 따라서

$$\begin{aligned} I(X;Y) &= \sum_{y \in Y} \sum_{x \in X} p(x,y) \log \left(\frac{p(x)p(y)}{p(x)p(y)} \right) \\ &= \sum_{y \in Y} \sum_{x \in X} p(x,y) \cdot 0 = 0 \end{aligned}$$

가 된다.

3. 탐구 내용 및 결과

동일한 시스템에서 동일한 사건 X 가 반복적으로 일어났다고 했을 때, 단순히 각 사건만 본다면 자기독립처럼 보일 수 있다. 수학적 확률을 구하기 어려운 경우 통계적 확률을 통해 판단하기 때문에 일정량의 오차를 고려한다면 많은 사건들이 자기독립처럼 보인다. 대표적인 것이 DNA의 염기서열이나 난수 생성기의 난수 나열들이다. 이러한 사건들을 단순히 바라본다면 이전 사건의 결과가 다음 사건에 영향을 미치지 않는 것처럼 보인다. 또다른 예시는 단어이다. 어떠한 글이 있을 때 다음에 나올 단어가 ‘사과’일 확률은 이전 단어에 크게 연관이 없어 보인다.


만약 어떠한 사건 X 가 자기독립이라면

$$P(X_t) = P(X_t | X_1, \dots, X_{t-1})$$

를 만족할 것이다. 즉, t 번 시행을 해서 t 번 때에서 X 가 일어날 확률을 계산할 때 이전 사건에 상관없이 X 가 일어날 확률과 $1 \sim t-1$ 번 때에 X 가 일어났을 때의 확률이 모두 같아야 한다는 것이다. 왜냐하면 자기독립이라면 이전의 결과에 다음 결과가 영향을 받지 않아야 하기 때문이다.


하지만 이러한 직관에서 의문이 생겼다. 세상의 많은 사건들이 자기독립이라면 그 사건들은 완전 무작위하게 일어날 것인데, 인공지능은 어떻게 그러한 사건들을 예측할 수 있는지에 대한 의문이 생겼다. 이에 따라 단어들이 순차적으로 나열된 글에서 단어의 분포가 자기독립을 만족시키는지 분석해보았다.

셰익스피어의 햄릿, 맥베스, 줄리어스 시저를 데이터셋으로 하여 이전 단어에 따른 다음 단어의 확률 분포를 분석해보았다.



그 결과 예상과 달리 균일하지 않은 확률분포를 얻을 수 있었다. 즉, 단어들의 분포는 완벽히 자기독립이 아닌 것이다.

동일하게 인간 미토콘드리아의 염기서열에서도 이전 염기에 따른 다음 염기의 확률 분포를 계산해보았다.



그 결과 염기서열 또한 완벽히 자기독립은 아니라는 것을 알 수 있었다.

하지만 두 결과를 통해 동일하기 자기독립이 아닌 두 분포이지만, 확률분포의 불균일성이 다르다는 것을 알 수 있었다. 이는 KL Divergence로 더욱 정량적으로 비교할 수 있었다. 단어에서의 확률분포는 1.9313, 염기서열에서의 확률분포는 0.0575로 단어에서의 확률분포가 염기서열에서보다 더 균일하지 않다는 것을 알 수 있었다.

이를 바탕으로 시간에 따른 조건부 확률의 분포의 변화를 정량화하여 어떠한 사건이 독립인 정도를 정량적으로 나타낼 수 있는 수식을 고안해보았다.

Ω : 상태공간

h_t : t번째 시점에 발생한 사건

$$H_k = (X_{t-k}, \dots, X_{t-1})$$

$$P_t = P(X_t | H_{t-1})$$

$$Q_t = P(X_t)$$

$$D_{KL}(P_t \parallel Q_t) = \sum_{x \in \Omega} P(X_t = x | H_{t-1}) \log \frac{P(X_t = x | H_{t-1})}{P(X_t = x)}$$

$$D_{KL}^k(P_t \parallel Q_t) = \sum_{x \in \Omega} P(X_t = x \mid H_k) \log \square \frac{P(X_t = x \mid H_k)}{P(X_t = x)}$$

이때 D_{KL} 하나의 값은 특정 시점에서 확률분포가 자기독립적이지 않은 정도를 나타내게 된다. 여기서 사용된 것은 KL Divergence 라고 하는 함수로 확률 분포 간의 차이를 측정하는 데에 사용될 수 있다. 위 식에서는 과거에 일어난 사건을 알고 있을 때 다음 사건이 발생할 조건부 확률 분포 P_t 와 과거를 전혀 모른 상태에서 다음 사건이 발생할 확률 분포 Q_t 간의 차이를 계산하고 있다.

시스템이 얼마나 자기독립이거나 자기독립이 아닌지를 나타내기 위해서는 특정 시점에서의 확률 분포만을 보는 것이 아니라, 가능한 모든 과거에 대해 확인해야 한다. 이에 따라 아래와 같이 위에서 정의한 D_{KL} 을 모든 과거 $h_1 \sim h_t$ 에 대해 구하여 그 기댓값을 계산하였다.

$$S_k = \sum_{h \in \Omega^t} P(h) \times D_{KL}^k(P(X_t \mid h) \parallel P(X_t))$$

$$S_k = \sum_{h \in \Omega^t} P(h) \sum_{x \in \Omega} P(x \mid h) \log \square \frac{P(x \mid h)}{P(x)}$$

이때 k 가 증가함에 따라 S_k 의 값은 증가하게 되고, 증가량을 비교함으로써 독립성을 비교할 수 있다. 만약 해당 사건이 완벽한 자기독립을 만족한다면 항상 과거의 사건의 결과에 따른 조건부 확률이 개별 확률과 동일하게 유지되고, KL-Divergence 의 값이 0 이 되어 $S_k = 0$

이 된다. 반대로 앞에서 예시를 들었던 단어의 분포와 같은 경우에는 앞에 등장한 단어의 나열에 따라 뒤에 등장할 수 있는 단어의 분포가 변화하기 때문에 KL-Divergence 의 값이 0 보다 커지게 되고, $S_k > 0$ 가 된다. 즉, 확률 분포가 더 크게 변화할수록 두 확률분포의 차이를 계산하는 KL-Divergence 의 값은 더 커져 S_k 의 값 또한 커지는 것을 알 수 있다.

여기에서 k 가 증가함에 따라 S_k 가 증가한다는 것을 수학적으로 증명하기 위해 아래와 같이 상호정보량의 정의를 이용하였다.

상호정보량은 아래와 같이 정의된다.

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} P(x,y) \log \left(\frac{P(x,y)}{P(x)P(y)} \right)$$

이때 $P(x,y) = P(x | y)P(y)$ 이므로

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} P(x | y)P(y) \log \left(\frac{P(x | y)P(y)}{P(x)P(y)} \right)$$

$$\color{red}{=} \sum_{y \in Y} P(y) \sum_{x \in X} P(x | y) \log \left(\frac{P(x | y)}{P(x)} \right)$$

정리된 식을 보면 앞에서 정의한 S_k 와 매우 유사하다는 것을 발견할 수 있었다.

즉, $S_k = I(X_t; H_k)$ 로 독립성을 평가하기 위해 정의했던 S_k 가 사실 상호정보량을 나타내고 있었던 것이다.

$S_k = I(X_t; H_k)$ 에서 H_k 의 정의에 의해

$$H_{k+1} = (X_{t-k-1}, H_k)$$

이고

$$S_{k+1} = I(X_t; H_{k+1}) = I(X_t; X_{t-k-1}, H_k)$$

가 성립한다. 이때 상호정보량의 연쇄법칙에 의해

$$I(X_t; X_{t-k-1}, H_k) = I(X_t; H_k) + I(X_t; X_{t-k-1} | H_k)$$

$$\color{red}{=} S_k + I(X_t; X_{t-k-1} | H_k)$$

의 형태로 분해된다. [2]

이때 조건부 상호정보량은 아래와 같이

$$I(A; B | C) = D_{KL}(P(a, b | c) \parallel P(x | z)P(y | Z))$$

KL-Divergence에 의해 계산되는데, KL-Divergence의 값은 0보다 같거나 큰 값을 가지므로

$I(X_t; X_{t-k-1} | H_k) \geq 0$ 은 항상 성립한다.


따라서

$$S_{k+1} \geq S_k$$

도 항상 성립한다. 즉, S_k 는 k 가 증가함에 따라 단조증가한다.

이를 실제 데이터에서도 확인해보기 위해 앞에서 사용했던 시계열 데이터를 동일하게 이용하여 k 에

따른 S_k 의 값을 계산해보았다.



그 결과, 인간 미토콘드리아 DNA 염기서열에서와 셰익스피어 작품 3 개에서의 단어 분포에서 둘 다 S_k 가 증가하는 것을 확인할 수 있었다. 또한 각각의 값이 증가하는 폭이 다르다는 것 또한 확인할 수 있었는데, 이를 통해 단어의 분포가 DNA 염기서열에서의 염기보다 더 이전 사건에 의존적이라는 것을 확인할 수 있다. 즉, 같은 크기의 상태공간이라고 가정한다면 단어의 분포가 DNA 염기서열보다 예측 가능성이 높고 예측 난이도가 더 낮은 것이다.

4. 정리 및 소감

실제 데이터를 분석해봄으로써 완전히 무작위적이고, 자기독립인 것처럼 보이는 사건들도 통계적으로 분석했을 때 유의미한 관계를 가지고 있다는 것을 알게 되었다. 또한 조건부 확률 분포와 개별 확률 분포 간의 차이를 KL-Divergence를 통해 정량화하고 이를 바탕으로 특정 사건이나 시스템이 독립이거나 독립이 아닌 정도를 일반화해보고, 이를 실제 데이터셋에 대해 적용해 계산해 봄으로써 자기독립이 아닌 사건들 안에서도 자기독립이 아닌 정도, 즉 과거의 사건에 영향을 받는 정도가 다르다는 것을 알 수 있었다. 뿐만 아니라 조건부 확률 분포의 변화로부터 유도한 식과 상호정보량의 공식이 동일하게 나타났다는 점이 신기했고, 독립성을 조사함으로써 분석하고자 했던 예측 가능성이 정보량과 관련이 있다는 점을 알게 되었다.

예시로부터 얻은 직관을 단순히 추측에서 끝내는 것이 아니라, 이를 수학적으로 분석하고 일반화해본 것이 의미 있었던 것 같고, 이 과정에서 유도한 식이 의미하는 바를 기존에 존재하던 이론과 연결하는

과정에서 같은 현상에 대한 다양한 해석이 가능하다는 것을 알 수 있었던 것 같다.

5. 참고 자료

[1] Mutual information, Wikipedia, 2026, 5, 1,

https://en.wikipedia.org/wiki/Mutual_information

[2] Anthropic Claude Sonnet, [https://claude.ai/share/c3d64c2f-db8b-4138-a16d-](https://claude.ai/share/c3d64c2f-db8b-4138-a16d-4557e14091cc)

[4557e14091cc](https://claude.ai/share/c3d64c2f-db8b-4138-a16d-4557e14091cc)